Universidad Politécnica de Atlautla

Fundamentos de Inteligencia Artificial

(Actividad Integradora 3.1 - Sección 1: Investigación)

Actividad Integradora 3.1: Tipos de aprendizaje automático

Del dato al bien social: modelos de IA para transformar realidades

Sección 1: Investigación.

Integrantes:

Sánchez Fragozo Dulce María - 24305056

Lopez Perez Veronica Juliette - 24305097

Rivera Andrade Jennifer - 24305072

Marín García Danna Isla - 24305080

Grupo: 171

Docente: García Lara Javier

06 de Noviembre del 2026

INDICE

1.1 Investigación conceptual 3
1.2 Clasificación del aprendizaje automático 5

06 de Noviembre del 2026

Introducción

El aprendizaje automático es la rama de la inteligencia artificial que construye sistemas capaces de mejorar su desempeño a partir de datos, en lugar de seguir reglas escritas una por una (Jordan & Mitchell, 2015). Esta investigación define el concepto, lo contrasta con la programación tradicional, precisa cuatro términos técnicos (dataset, etiqueta, feature y función de pérdida) y clasifica diez aplicaciones reales según su tipo de aprendizaje.

Las fuentes combinan artículos científicos arbitrados (*Science*, *Nature*, *JAMA*, ACM) con documentación técnica de Google e IBM. Todas las referencias incluyen DOI o enlace directo y fecha de consulta cuando son páginas web.

1.1 Investigación conceptual

1.1.1 Concepto de aprendizaje automático

El aprendizaje automático estudia cómo construir computadoras que mejoren de forma automática con la experiencia; se ubica entre las ciencias de la computación y la estadística y forma parte del núcleo de la inteligencia artificial y la ciencia de datos (Jordan & Mitchell, 2015). Sarker (2021) lo describe como la capacidad de un sistema de aprender y mejorar a partir de la experiencia sin ser programado de manera específica para cada caso, y lo organiza en cuatro tipos: supervisado, no supervisado, semisupervisado y por refuerzo. Históricamente, Samuel (1959) mostró que un programa de damas podía aprender a jugar mejor que la persona que lo escribió.

Definición propia. El aprendizaje automático es un conjunto de métodos con los que un programa ajusta sus parámetros internos a partir de ejemplos, para mejorar en una tarea cuyo desempeño se puede medir y para responder bien ante datos que nunca vio. Por eso es una rama de la inteligencia artificial y no algo distinto de ella.

Programación tradicional frente a aprendizaje automático

La diferencia está en de dónde sale la lógica del programa. En la programación tradicional, una persona escribe las reglas; en el aprendizaje automático, el algoritmo infiere esas reglas a partir de ejemplos de entradas y salidas deseadas. Jordan y Mitchell (2015) señalan que, para

muchas aplicaciones, es más fácil entrenar un sistema mostrándole ejemplos que programarlo anticipando la respuesta para todas las entradas posibles.

Aspecto	Programación tradicional	Aprendizaje automático
Qué entrega la persona	Reglas explícitas	Ejemplos (datos) y una medida de error
Qué produce el proceso	Un resultado a partir de datos y reglas	Un modelo (las reglas aprendidas)
Ante un caso nuevo	Solo funciona si la regla lo prevé	Generaliza a partir de lo aprendido
Para mejorar	Se reescribe el código	Se reentrena con más o mejores datos

Ejemplo. Un filtro de correo no deseado tradicional necesitaría reglas escritas a mano sobre palabras o remitentes. Uno basado en aprendizaje automático aprende de correos que los usuarios marcaron como spam o no spam, y usa características como las palabras del texto, la dirección del remitente y la hora de envío (Google for Developers, s. f.).

Dataset, etiqueta, feature y función de pérdida

Dataset. Es un conjunto organizado de ejemplos con el que se entrena y se evalúa un modelo; Gebru et al. (2021) subrayan que todo modelo de aprendizaje automático se entrena y se evalúa con datos, y proponen documentar cada dataset con su motivación, composición, proceso de recolección y usos recomendados. Sarker (2021) distingue datos estructurados, semiestructurados y no estructurados.

Etiqueta (label). Es la respuesta correcta que se quiere predecir, representada como *y* (Google for Developers, s. f.). El etiquetado de datos consiste en identificar datos crudos, como imágenes, texto o video, y asignarles una o más etiquetas que den contexto al modelo; los datos etiquetados se usan en el aprendizaje supervisado y los no etiquetados en el no supervisado, y etiquetar suele ser costoso y lento (IBM, s. f.-b). Por ejemplo, Esteva et al. (2017) entrenaron su modelo con imágenes clínicas etiquetadas por dermatólogos.

Feature (característica). Es una variable de entrada, representada como *x* (Google for Developers, s. f.). Zheng y Casari (2018) definen la ingeniería de características como extraer features de los datos crudos y transformarlos a un formato adecuado para el modelo. Un ejemplo (features, etiqueta) se escribe como el par (*x*, *y*).

Función de pérdida. Mide el desempeño del modelo calculando cuánto se desvían sus predicciones de los valores correctos o "verdad fundamental"; entrenar consiste en ajustar los parámetros para minimizarla, y es sinónimo habitual de función de costo o de error (IBM, s. f.-a). Si las predicciones son buenas, la pérdida es pequeña; si son malas, es grande. Google for Developers (s. f.) presenta como ejemplo el error cuadrático medio (MSE), que promedia la pérdida cuadrática de todos los ejemplos:

```
MSE = \frac{1}{N} \sum_{(x,y) \in D} \left( y - \text{prediccion}(x) \right)^2
```

En conjunto, el ciclo es: el dataset aporta ejemplos (*x*, *y*); el modelo predice a partir de las features; la función de pérdida compara la predicción con la etiqueta; y el entrenamiento ajusta los parámetros para reducir esa pérdida.

1.2 Clasificación del aprendizaje automático

El criterio principal para clasificar el aprendizaje automático es el tipo de señal con la que aprende el modelo. Sarker (2021) reconoce cuatro tipos: supervisado, no supervisado, semisupervisado y por refuerzo.

- **Supervisado:** aprende de ejemplos con etiqueta; los datos etiquetados se usan en este tipo de aprendizaje (IBM, s. f.-b).
- **No supervisado:** trabaja con datos sin etiquetar y puede descubrir grupos nuevos en los datos (IBM, s. f.-b).
- **Semisupervisado:** combina ejemplos etiquetados con otros sin etiquetar, por ejemplo transacciones de tarjeta de crédito con y sin etiqueta (Jordan & Mitchell, 2015).
- **Por refuerzo:** un agente aprende a controlar un entorno optimizando su conducta con base en la experiencia (Mnih et al., 2015).

#	Aplicación real	Tipo de aprendizaje	Qué aprende y con qué datos	Fuente
1	Filtro de correo no deseado	Supervisado (clasificación)	Distingue spam de no spam con correos que los usuarios etiquetaron; usa features como palabras, remitente y hora	Google for Developers (s. f.)
2	Detección de cáncer de piel	Supervisado (clasificación de imágenes)	Red neuronal convolucional entrenada con 129,450 imágenes clínicas de 2,032 enfermedades, etiquetadas por dermatólogos; igualó el desempeño de especialistas en las pruebas	Esteva et al. (2017)
3	Detección de retinopatía diabética	Supervisado (clasificación de imágenes)	Red profunda entrenada con 128,175 imágenes de retina calificadas por oftalmólogos para detectar retinopatía referible	Gulshan et al. (2016)
4	Diagnóstico de enfermedades de plantas	Supervisado (clasificación de imágenes)	Red convolucional entrenada con 54,306 imágenes de hojas de 14 cultivos y 26 enfermedades; 99.35 % de exactitud en un conjunto de prueba reservado	Mohanty et al. (2016)
5	Reconocimiento de voz	Supervisado (redes neuronales profundas)	Modelado acústico con redes profundas, que superaron a los modelos de mezclas gaussianas en varias pruebas de referencia	Hinton et al. (2012)
6	Detección de anomalías (tráfico de red anómalo,	No supervisado o semisupervisado, según haya	Aprende qué es comportamiento normal y marca lo que se desvía; la técnica depende de si hay datos etiquetados	Chandola et al. (2009)

#	Aplicación real	Tipo de aprendizaje	Qué aprende y con qué datos	Fuente
	transacciones sospechosas)	etiquetas		
7	Sistema de recomendación de Netflix	Híbrido (varios enfoques)	Conjunto de algoritmos que ayudan a los miembros a encontrar videos; el artículo aclara que no es un solo algoritmo	Gomez-Uribe & Hunt (2015)
8	Modelo de lenguaje GPT-3	Autosupervisado (clasificación del equipo)	Modelo autorregresivo de 175 mil millones de parámetros, preentrenado con grandes corpus de texto; resuelve tareas con pocos ejemplos, sin ajuste fino	Brown et al. (2020)
9	AlphaGo (juego de Go)	Supervisado y por refuerzo	Redes que aprendieron de partidas de expertos humanos y después de partidas contra sí mismo; superó al campeón europeo de Go 5 a 0	Silver et al. (2016)
10	Agente DQN para videojuegos de Atari	Por refuerzo	Aprende políticas de juego a partir de píxeles y puntaje; alcanzó nivel comparable al de un probador humano profesional en 49 juegos	Mnih et al. (2015)

Las aplicaciones 2, 3 y 4 son las más cercanas al enfoque de bien social: salud y seguridad alimentaria. Mohanty et al. (2016) describen su resultado como un primer paso hacia el diagnóstico asistido por teléfono, no como un sistema terminado.

Para elegir el tipo de aprendizaje, la pregunta práctica es qué datos hay: con etiquetas conviene el enfoque supervisado, sin etiquetas el no supervisado, y si un agente puede actuar y recibir resultados en un entorno, el aprendizaje por refuerzo.

Conclusiones

El aprendizaje automático es una rama de la inteligencia artificial en la que el modelo obtiene sus reglas de los datos y no de instrucciones escritas a mano, lo que lo hace útil cuando definir reglas explícitas es difícil (Jordan & Mitchell, 2015).

Cuatro conceptos sostienen todo el proceso: el dataset aporta los ejemplos, las features describen cada ejemplo, la etiqueta es la respuesta correcta y la función de pérdida mide cuánto se equivoca el modelo para poder corregirlo.

La tabla de diez aplicaciones muestra que el tipo de aprendizaje depende de los datos disponibles: etiquetas, ausencia de ellas o interacción con un entorno. Tres casos (cáncer de piel, retinopatía diabética y enfermedades de plantas) apuntan a problemas sociales, aunque sus autores los presentan como estudios de factibilidad y no como soluciones terminadas.

Referencias

Anthropic. (2026). *Claude* (versión Sonnet 5.5) [Modelo de lenguaje de gran tamaño]. https://claude.ai

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., ... Amodei, D. (2020). *Language models are few-shot learners*. arXiv. https://doi.org/10.48550/arXiv.2005.14165

Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. *ACM Computing Surveys, 41*(3), Art. 15. https://doi.org/10.1145/1541880.1541882

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature, 542*(7639), 115–118. https://doi.org/10.1038/nature21056

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86–92. https://doi.org/10.1145/3458723

Gomez-Uribe, C. A., & Hunt, N. (2015). The Netflix recommender system: Algorithms, business value, and innovation. *ACM Transactions on Management Information Systems, 6*(4), Art. 13. https://doi.org/10.1145/2843948

Google for Developers. (s. f.). *Machine learning crash course*. Recuperado el 5 de noviembre de 2026, de https://developers.google.com/machine-learning/crash-course

Gulshan, V., Peng, L., Coram, M., Stumpe, M. C., Wu, D., Narayanaswamy, A., Venugopalan, S., Widner, K., Madams, T., Cuadros, J., Kim, R., Raman, R., Nelson, P. C., Mega, J. L., & Webster, D. R. (2016). Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. *JAMA, 316*(22), 2402–2410. https://doi.org/10.1001/jama.2016.17216

Hinton, G., Deng, L., Yu, D., Dahl, G. E., Mohamed, A., Jaitly, N., Senior, A., Vanhoucke, V., Nguyen, P., Sainath, T. N., & Kingsbury, B. (2012). Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups. *IEEE Signal Processing Magazine, 29*(6), 82–97. https://doi.org/10.1109/MSP.2012.2205597

IBM. (s. f.-a). *What is a loss function?* Recuperado el 5 de noviembre de 2026, de https://www.ibm.com/think/topics/loss-function

IBM. (s. f.-b). *What is data labeling?* Recuperado el 5 de noviembre de 2026, de https://www.ibm.com/think/topics/data-labeling

Jordan, M. I., & Mitchell, T. M. (2015). Machine learning: Trends, perspectives, and prospects. *Science, 349*(6245), 255–260. https://doi.org/10.1126/science.aaa8415

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature, 518*(7540), 529–533. https://doi.org/10.1038/nature14236

Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science, 7*, Art. 1419. https://doi.org/10.3389/fpls.2016.01419

Samuel, A. L. (1959). Some studies in machine learning using the game of checkers. *IBM Journal of Research and Development, 3*(3), 210–229. https://doi.org/10.1147/rd.33.0210

Sarker, I. H. (2021). Machine learning: Algorithms, real-world applications and research directions. *SN Computer Science, 2*(3), Art. 160. https://doi.org/10.1007/s42979-021-00592-x

Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., van den Driessche, G., Schrittwieser, J., Antonoglou, I., Panneershelvam, V., Lanctot, M., Dieleman, S., Grewe, D., Nham, J., Kalchbrenner, N., Sutskever, I., Lillicrap, T., Leach, M., Kavukcuoglu, K., Graepel, T., & Hassabis, D. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature, 529*(7587), 484–489. https://doi.org/10.1038/nature16961

Zheng, A., & Casari, A. (2018). *Feature engineering for machine learning: Principles and techniques for data scientists*. O'Reilly Media.

Google. (2026). Gemini AI(Versión de Noviembre de 2026) [Modelo de lenguaje grande]. google.com

Anthropic. (2026). Claude (versión Sonnet 5.5) [Modelo de lenguaje de gran tamaño]. https://claude.ai

OpenAI. (2026). ChatGPT (GPT-6) [Modelo de lenguaje grande]. https://chatgpt.com/

Declaración de uso de IA generativa

Se usó Claude (Anthropic, Chat gpt y Gemini AI,2026) para la relizacion del promt, estructura de plan de desarrollo para la realizacion del documento y correccion ortografica del mismo.